### Lösungen zu den Aufgaben

#### 1. Aufgabe

Melden Sie sich an für die Kaggle Competition TMDB Box Office Prediction - Can you predict a movie's worldwide box office revenue?

Sie benötigen dazu ein Konto; es ist auch möglich, sich mit seinem Google-Konto anzumelden.

Bei diesem Prognosewettbewerb geht es darum, vorherzusagen, wieviel Umsatz wohl einige Filme machen werden. Als Prädiktoren stehen einige Infos wie Budget, Genre, Titel etc. zur Verfügung. Eine klassische "predictive Competition" also :-) Allerdings können immer ein paar Schwierigkeiten auftreten ;-)

#### Aufgabe

Erstellen Sie ein Random-Forest-Modell mit Tidymodels! Reichen Sie es bei Kaggle ein un berichten Sie den Score!

#### Hinweise

- Verzichten Sie auf Vorverarbeitung.
- o Tunen Sie die typischen Parameter.
- o Begrenzen Sie sich auf folgende Prädiktoren.

```
preds_chosen <-
  c("id", "budget", "popularity", "runtime")</pre>
```

#### Lösung

### Pakete starten

```
library(tidyverse)
library(tidymodels)
library(tictoc)
```

# **Daten importieren**

```
d_train_path <- "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/tmdb-box-office-prediction/train.csv"
d_test_path <- "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/tmdb-box-office-prediction/test.csv"

d_train <- read_csv(d_train_path)
d test <- read_csv(d test_path)</pre>
```

#### Werfen wir einen Blick in die Daten:

```
glimpse(d train)
## Rows: 3,000
## Columns: 23
## $ budget
## $ genres
## $ homepage
<dbl> 6.575393, 8.248895, 64.299990, 3.1749...
## $ popularity
                     <chr> "/tQtWuwvMf0hCc2QR2tkolw17c3c.jpg", "...
## $ poster path
cchr> "2/20/15", "8/6/04", "10/10/14", "3/9...
<dbl> 93, 113, 105, 122, 118, 83, 92, 84, 1...
<chr> "[{'iso_639_1': 'en', 'name': 'Englis...
<chr> "Released", "Released", "Released", "...
<chr> "The Laws of Space and Time are About...
<chr> "Hot Tub Time Machine 2", "The Prince...
<chr> "[{'id': 4379, 'name': 'time travel'}...
## $ runtime
## $ spoken_languages
## $ status
## $ tagline
## $ title
## $ Keywords
                     ## $ cast
## $ crew
                     <dbl> 12314651, 95149435, 13092000, 1600000...
## $ revenue
glimpse(d test)
## Rows: 4,398
## Columns: 22
## $ id
                     <dbl> 3001, 3002, 3003, 3004, 3005, 3006, 3...
## $ belongs_to_collection <chr>> "[{'id': 34055, 'name': 'Pokémon Coll...
             ## $ budget
## $ genres
                     <chr> "http://www.pokemon.com/us/movies/mov...
## $ homepage
## $ overview
                     <dbl> 3.851534, 3.559789, 8.085194, 8.59601...
## $ popularity
```

preds chosen sind alle Prädiktoren im Datensatz, oder nicht? Das prüfen wir mal kurz:

```
preds_chosen %in% names(d_train) %>%
   all()
## [1] TRUE
```

Ja, alle Elemente von preds chosen sind Prädiktoren im (Train-)Datensatz.

### CV

```
cv_scheme <- vfold_cv(d_train)
```

# Rezept 1

```
rec1 <-
 recipe(revenue ~ budget + popularity + runtime, data = d train) %>%
  step_impute_bag(all_predictors()) %>%
  step_naomit(all_predictors())
rec1
## Recipe
##
## Inputs:
##
        role #variables
##
     outcome
   predictor
                       3
##
## Operations:
##
## Bagged tree imputation for all predictors()
## Removing rows with NA values in all predictors()
```

Man beachte, dass noch 21 Prädiktoren angezeigt werden, da das Rezept noch nicht auf den Datensatz angewandt ("gebacken") wurde.

#### Rezept checken:

```
prep(rec1)
## Recipe
## Inputs:
##
         role #variables
      outcome
##
   predictor
\#\# Training data contained 3000 data points and 2 incomplete rows.
## Operations:
## Bagged tree imputation for budget, popularity, runtime [trained]
## Removing rows with NA values in budget, popularity, runtime [trained]
d train baked <-
  rec1 %>%
  prep() %>%
  bake(new_data = NULL)
glimpse(d train baked)
## Rows: 3,000
## Columns: 4
## $ budget
                  <dbl> 1.40e+07, 4.00e+07, 3.30e+06, 1.20e+06, 0.00e+00...
## $ popularity <dbl> 6.575393, 8.248895, 64.299990, 3.174936, 1.14807...
## $ runtime <dbl> 93, 113, 105, 122, 118, 83, 92, 84, 100, 91, 119...
                  <dbl> 12314651, 95149435, 13092000, 16000000, 3923970,...
```

### Modell 1: RF

```
\label{eq:model1} $$\operatorname{model1} <- \operatorname{rand\_forest}(\operatorname{mtry} = \operatorname{tune}(), \\ & \operatorname{trees} = \operatorname{tune}(), \\ & \min_n = \operatorname{tune}()) \ \$ > \$ \\ & \operatorname{set\_engine}('\operatorname{ranger}') \ \$ > \$ \\ & \operatorname{set\_mode}('\operatorname{regression}') $$
```

### **Workflow 1**

```
wf1 <-
  workflow() %>%
  add_model(model1) %>%
  add_recipe(rec1)
```

# Modell fitten (und tunen)

```
doParallel::registerDoParallel(4)
tic()
rf_fit1 <-
    wf1 %>%
    tune_grid(resamples = cv_scheme)
toc()
## 69.079 sec elapsed
rf_fit1[[".notes"]][1]
## [[1]]
## A tibble: 0 × 3
## # m. with 3 variables: location <chr>, type <chr>, note <chr>
```

# **Bester Kandidat**

# **Workflow Finalisieren**

```
wf_best <-
   wf1 %>%
   finalize_workflow(parameters = select_best(rf_fit1))
## Warning: No value of `metric` was given; metric 'rmse' will be used.
```

# **Final Fit**

x), num.trees = ~1124L, min.node.size = min rows(~4L, x),

```
## Type:
                                       Regression
## Number of trees:
                                        1124
                                        3000
## Sample size:
## Number of independent variables:
## Mtry:
## Target node size:
## Variable importance mode:
## Splitrule:
                                       variance
## Splitrule: variance
## OOB prediction error (MSE): 6.572476e+15
## R squared (00B):
                                       0.6525283
  fit1_final %>%
  predict(d_test)
```

### Submission df

```
submission df <-
 d test %>%
  select(id) %>%
  bind cols(preds) %>%
  rename (revenue = .pred)
head(submission_df)
## # A tibble: 6 \times 2
       id revenue
     <dbl>
##
              <db1>
## 1 3001 4417241.
## 2 3002 5509047.
## 3 3003 13764032.
## 4 3004 38653947.
     3005 3940693.
## 6 3006 22111594.
```

#### Abspeichern und einreichen:

```
#write_csv(submission_df, file = "submission.csv")
```

# **Kaggle Score**

Diese Submission erzielte einen Score von Score: 2.76961 (RMSLE).

```
sol <- 2.76961
```

#### 2. Aufgabe

Wir bearbeiten hier die Fallstudie TMDB Box Office Prediction - Can you predict a movie's worldwide box office revenue?, ein Kaggle-Prognosewettbewerb.

Ziel ist es, genaue Vorhersagen zu machen, in diesem Fall für Filme.

Die Daten können Sie von der Kaggle-Projektseite beziehen oder so:

```
d_train_path <- "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/tmdb-box-office-prediction/train.csv"
d_test_path <- "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/tmdb-box-office-prediction/test.csv"</pre>
```

# **Aufgabe**

Reichen Sie bei Kaggle eine Submission für die Fallstudie ein! Berichten Sie den Kaggle-Score

#### Hinweise:

- o Sie müssen sich bei Kaggle ein Konto anlegen (kostenlos und anonym möglich); alternativ können Sie sich mit einem Google-Konto anmelden.
- Berechnen Sie einen Entscheidungsbaum und einen Random-Forest.
- o Tunen Sie nach Bedarf; verwenden Sie aber Default-Werte.
- Verwenden Sie Tidymodels.

#### Lösung

# Vorbereitung

```
library(tidyverse)
library(tidymodels)
library(tictoc)
d_train <- read_csv(d_train_path)
d_test <- read_csv(d_test_path)
glimpse(d_train)</pre>
```

```
## Rows: 3,000
## Columns: 23
<chr> "tt2637294", "tt0368933", "tt2582802"...
<chr> "en", "en", "en", "hi", "ko", "en", "...
<chr> "Hot Tub Time Machine 2", "The Prince...
## $ imdb_id
## $ original_language
## $ original_title
                        <chr> "When Lou, who has become the \"fathe...
<db> 6.575393, 8.248895, 64.299990, 3.1749...
## $ overview
## $ popularity
                         <chr> "/tQtWuwvMf0hCc2QR2tkolw17c3c.jpg",
## $ poster path
## $ tagline
                        <chr> "The Laws of Space and Time are About...
                        <chr> "Hot Tub Time Machine 2", "The Prince...
## $ title
                        <chr> "[{'id': 4379, 'name': 'time travel'}...
## $ Keywords
                        <chr> "[{'cast_id': 4, 'character': 'Lou', ...
<chr> "[{'credit_id': '59ac067c92514107af02...
## S cast
## $ crew
                        <dbl> 12314651, 95149435, 13092000, 1600000...
## $ revenue
glimpse(d test)
## Rows: 4,398
## Columns: 22
<dbl> 0.00e+00, 8.80e+04, 0.00e+00, 6.80e+0...
## $ budget
                         <chr> "[{'id': 12, 'name': 'Adventure'}, {'...
## $ genres
## $ homepage
                         <chr> "http://www.pokemon.com/us/movies/mov...
<chr> "ディアルガvsパルキアvsダークライ", "...
## $ original_title
## $ overview
                        <chr> "Ash and friends (this time accompani...
## $ popularity
                        <dbl> 3.851534, 3.559789, 8.085194, 8.59601...
                         <chr> "/tnftmLMemPLduW6MRyZE0ZUD19z.jpg", "...
## $ poster_path
                        <chr> "[{'id': 11451, 'name': 'pok√@mon'}, ...
## $ Keywords
                         chr> "[{'cast_id': 3, 'character': 'Tonio'...
<chr> "[{'credit_id': '52fe44e7c3a368484e03...
```

# Rezpet

### Rezept definieren

```
recipe(revenue ~ ., data = d_train) %>%
  update_role(all_predictors(), new_role = "id") %>%
  update_role(popularity, runtime, revenue, budget) %>%
update_role(revenue, new_role = "outcome") %>%
  step mutate(budget = ifelse(budget < 10, 10, budget)) %>%
  step log(budget) %>%
  step_impute_knn(all_predictors())
rec1
## Recipe
## Inputs:
         role #variables
     outcome
## predictor
                         3
## Operations:
## Variable mutation for ifelse(budget < 10, 10, budget)
## Log transformation on budget
## K-nearest neighbor imputation for all predictors()
```

### **Check das Rezept**

```
recl_prepped <-
   prep(rec1, verbose = TRUE)

## oper 1 step mutate [training]
## oper 2 step log [training]
## oper 3 step impute knn [training]
## oper 3 step impute knn [training]
## The retained training set is ~ 28.71 Mb in memory.</pre>
```

```
rec1_prepped
## Recipe
## Inputs:
         role #variables
##
           id
     outcome
   predictor
## Training data contained 3000 data points and 2793 incomplete rows.
## Operations:
## Variable mutation for ~ifelse(budget < 10, 10, budget) [trained]
## Log transformation on budget [trained]
## K-nearest neighbor imputation for popularity, runtime, budget [trained]
d train baked <-
  rec1 prepped %>%
  bake(new_data = NULL)
head(d train baked)
## # A tibble: 6 × 23
        id belongs_to_collection
                                             budget genres homepage imdb_id
##
     <dbl> <fct>
                                              <dbl> <fct> <fct>
                                                                      <fct>
         1 [{'id': 313576, 'name': 'Hot ...
                                                     [{'id... <NA>
## 1
                                                                       tt2637...
                                              16.5
         2 [{'id': 107674, 'name': 'The ... 17.5
                                                     [{'id... <NA>
## 2
                                                                       tt0368...
                                                     [{'id... http://... tt2582...
         4 <NA>
                                                     [{'id... http://... tt1821...
         5 <NA>
## 5
                                               2.30
                                                     [{'id... <NA>
         6 <NA>
                                              15.9
                                                     [{'id... <NA>
## # ... with 17 more variables: original language <fct>,
       original title <fct>, overview <fct>, popularity <dbl>, poster_path <fct>, production_companies <fct>,
       production countries <fct>, release date <fct>, runtime <dbl>,
       spoken_languages <fct>, status <fct>, tagline <fct>,
## #
       title <fct>, Keywords <fct>, cast <fct>, crew <fct>,
## #
       revenue <dbl>
Die AV-Spalte sollte leer sein:
bake(rec1_prepped, new_data = head(d_test), all_outcomes())
## # A tibble: 6 × 0
d train baked %>%
  map_df(~ sum(is.na(.)))
## # A tibble: 1 × 23
##
        id belongs_to_collection budget genres homepage imdb_id
##
     <int>
                            <int> <int> <int>
                                                     <int>
                                                              <int>
                              2396
                                                       2054
   # ... with 17 more variables: original_language <int>,
       original_title <int>, overview <int>, popularity <int>,
       poster_path <int>, production_companies <int>,
## #
       production_countries <int>, release_date <int>, runtime <int>,
       spoken_languages <int>, status <int>, tagline <int>,
title <int>, Keywords <int>, cast <int>, crew <int>,
       revenue <int>
```

Keine fehlenden Werte mehr in den Prädiktoren.

Nach fehlenden Werten könnte man z.B. auch so suchen:

datawizard::describe\_distribution(d\_train\_baked)

### variable | mean | sd | iqr | range | skewness | kurtosis | n | n\_missing

 $\begin{array}{l} \text{id} \mid 1500.50 \mid 866.17 \mid 1500.50 \mid [1.00, 3000.00] \mid 0.00 \mid -1.20 \mid 3000 \mid 0 \text{ budget} \mid 12.51 \mid 6.44 \mid 14.88 \mid [2.30, 19.76] \mid -0.87 \mid -1.09 \mid 3000 \mid 0 \text{ popularity} \\ \mid 8.46 \mid 12.10 \mid 6.88 \mid [1.00e-06, 294.34] \mid 14.38 \mid 280.10 \mid 3000 \mid 0 \text{ runtime} \mid 107.85 \mid 22.08 \mid 24.00 \mid [0.00, 338.00] \mid 1.02 \mid 8.20 \mid 3000 \mid 0 \text{ revenue} \mid \\ \mid 6.67e+07 \mid 1.38e+08 \mid 6.66e+07 \mid [1.00, 1.52e+09] \mid 4.54 \mid 27.78 \mid 3000 \mid 0 \\ \end{array}$ 

So bekommt man gleich noch ein paar Infos über die Verteilung der Variablen. Praktische Sache.

Das Test-Sample backen wir auch mal:

```
d test baked <-
 bake(rec1_prepped, new_data = d_test)
d test baked %>%
  head()
## # A tibble: 6 × 22
        id belongs_to_collection
                                            budget genres homepage imdb id
     <dbl> <fct>
                                             <dbl> <fct> <fct>
## 1 3001 [{'id': 34055, 'name': 'Pokém...
## 2 3002 <NA>
                                                    [{'id... <NA>
                                                                     <NA>
                                              2.30 [{'id... <NA>
## 3 3003 <NA>
                                                                     <NA>
                                             15.7 <NA> <NA> 14.5 [{'id... <NA>
## 4 3004 <NA>
                                                                     <NA>
## 5 3005 <NA>
                                                                     <NA>
## 6 3006 <NA>
                                              2.30 [{'id... <NA>
                                                                     <NA>
## # ... with 16 more variables: original language <fct>,
```

```
## # original_title <fct>, overview <fct>, popularity <dbl>,
## # poster_path <fct>, production_companies <fct>,
## production_countries <fct>, runtime <dbl>,
## spoken_languages <fct>, status <fct>, tagline <fct>,
## # title <fct>, Keywords <fct>, cast <fct>, crew <fct>
```

# Kreuzvalidierung

### Modelle

#### **Baum**

#### **Random Forest**

### **Workflows**

```
wf_tree <-
workflow() %>%
  add_model(mod_tree) %>%
  add_recipe(rec1)

wf_rf <-
  workflow() %>%
  add_model(mod_rf) %>%
  add_recipe(rec1)
```

# Fitten und tunen

#### Tree

```
tic()
tree_fit <-
   wf_tree %>%
   tune_grid(
   resamples = cv_scheme,
   grid = 2
)
toc()
## 7.227 sec elapsed
```

Hilfe zu tune\_grid() bekommt man hier.

```
tree fit
## # Tuning results
## # 5-fold cross-validation repeated 3 times
## # A tibble: 15 × 5
           splits
                                                                                         id
                                                                                                                     id2 .metrics
                   st>
                                                                                          <chr> <chr< <li><chr> <chr< <li><chr< <l><chr< <li><chr< <l><chr< </t>
          1 <split [2400/600]> Repeat1 Fold1 <tibble [4 \times 6]> <tibble [0 \times 3]>
          2 <split [2400/600]> Repeat1 Fold2 <tibble [4 × 6]> <tibble [0 × 3]>
          3 3 4 split [2400/600]> Repeat1 Fold3 <tibble [4 × 6]> <tibble [0 × 3]>
4 4 split [2400/600]> Repeat1 Fold4 <tibble [4 × 6]> <tibble [0 × 3]>
           5 <split [2400/600]> Repeat1 Fold5 <tibble [4 × 6]> <tibble [0 × 3]>
              6 <split [2400/600] > Repeat2 Fold1 <tibble [4 \times 6] > <tibble [0 \times 3] >
          7 <split [2400/600]> Repeat2 Fold2 <tibble [4 × 6]> <tibble [0 × 3]> 8 <split [2400/600]> Repeat2 Fold3 <tibble [4 × 6]> <tibble [0 × 3]> 9 <split [2400/600]> Repeat2 Fold4 <tibble [4 × 6]> <tibble [0 × 3]>
## 10 <split [2400/600]> Repeat2 Fold5 <tibble [4 × 6]> <tibble [0 × 3]> ## 11 <split [2400/600]> Repeat3 Fold1 <tibble [4 × 6]> <tibble [0 × 3]>
## 12 <split [2400/600] > Repeat3 Fold2 <tibble [4 \times 6] > <tibble [0 \times 3] >
## 13 split [2400/600]> Repeat3 Fold3 <tibble [4 × 6]> <tibble [0 × 3]>
## 14 <split [2400/600]> Repeat3 Fold4 <tibble [4 × 6]> <tibble [0 × 3]>
## 15 <split [2400/600]> Repeat3 Fold5 <tibble [4 × 6]> <tibble [0 × 3]>
```

```
Steht was in den .notes?
tree fit[[".notes"]][[2]]
## # A tibble: 0 \times 3
## # ... with 3 variables: location <chr>, type <chr>, note <chr>
Nein.
collect_metrics(tree_fit)
## # A tibble: 4 × 8
   cost_complexity tree_depth .metric .estimator
                          ##
               <db1>
                                                       \langle db1 \rangle \langle int \rangle \langle \overline{d}b1 \rangle
            5.38e-10
                                                                15 1.59e+6
## 1
## 2
            5.38e-10
                                                                 15 1.41e-2
                                        standard
## 3
                                                     9.09e+7
                                                                 15 1.58e+6
            5.23e- 6
                               3 rmse
                                         standard 5.58e-1
            5.23e- 6
                               3 rsq
                                                                15 1.77e-2
## # ... with 1 more variable: .config <chr>
show best(tree fit)
## Warning: No value of `metric` was given; metric 'rmse' will be used.
## # A tibble: 2 × 8
##
   cost_complexity tree_depth .metric .estimator
                                                       mean
                                                                 n std_err
                                                       ##
               <dbl>
                           <int> <chr> <chr>
                           13 rmse
## 1
            5.38e-10
                                        standard
                                                     8.93e7
                                         standard 9.09e7
## 2
            5.23e- 6
                                                                15 1.58e6
                              3 rmse
## # \dots with 1 more variable: .config <chr>
Finalisieren
best_tree_wf <-
  wf_tree %>%
  finalize workflow(select best(tree fit))
## Warning: No value of `metric` was given; metric 'rmse' will be used.
best tree wf
## == Workflow :
## Preprocessor: Recipe
## Model: decision tree()
## -- Preprocessor
## 3 Recipe Steps
## • step_mutate()
## • step_log()
## • step_impute_knn()
##
## Decision Tree Model Specification (regression)
## Main Arguments:
   cost_complexity = 5.37967376130334e-10
##
##
    tree_depth = 13
## Computational engine: rpart
tree last fit <-
 fit(best_tree_wf, data = d_train)
tree_last_fit
## == Workflow [trained]
## Preprocessor: Recipe
## Model: decision_tree()
## -- Preprocessor -
## 3 Recipe Steps
## • step_mutate()
## • step_log()
## • step_impute_knn()
##
## -- Model
## n= 3000
## node), split, n, deviance, yval
         * denotes terminal node
##
       1) root 3000 5.672651e+19 66725850.0
2) budget< 18.32631 2845 1.958584e+19 46935270.0
4) budget< 17.19976 2252 5.443953e+18 25901120.
##
##
                                                    25901120.0
             8) popularity< 9.734966 1745 1.665118e+18 17076460.0
              3) popularity< 9.734966 1745 1.0001100110 16) popularity< 5.761331 1019 3.184962e+17 879373(
                   64) popularity< 1.517383 293 1.907705e+16 3025921.0
                         1024) popularity< 1.140496 99 3.624224e+14
                                                                          960819.7
                           2048) popularity< 0.18234 26 2.613956e+12
                                                                           283857.7
                                                                          212028.9 *
                             4096) budget< 10.99014 19 1.656689e+12
4097) budget>=10.99014 7 5.931626e+11
                                                                         478821.6 *
```

```
2049) popularity>=0.18234 73 3.436495e+14
                                4098) runtime< 92 48 1.563662e+14
                                                                           942088.9
                                  8196) popularity< 0.698595 23 1.197191e+13
                                                                                        472543.1 *
                                8197) popularity>=0.698595 25 1.346582e+14 4099) runtime>=92 25 1.778200e+14 1700823
                                                                                      1374071.0 *
                                                                          1700823.0
                                  8198) popularity>=0.319976 17 3.705079e+13
                                                                                      1197195.0 *
                                                                                    2771033.0 *
                                  8199) popularity< 0.319976 8 1.272946e+14
                           1025) popularity>=1.140496 19 2.584278e+14
                                                                                2470148.0 *
                          513) runtime>=96.5 130 4.381186e+15
                                                                      2920503.0
                           1026) popularity< 0.4028185 33 1.196999e+14
                                                                                1118933.0
                                                                            102104.2 *
                             2052) runtime< 104.5 13 2.411497e+11
                             2053) runtime>=104.5 20 9.728066e+13
                                                                           1779872.0
                                4106) runtime>=121.5 10 9.005154e+12
                                4107) runtime< 121.5 10 7.483801e+13
                                                                            2599552.0 *
                           1027) popularity>=0.4028185 97 4.117942e+15
                                                                                3533408.0
                             2054) popularity>=0.4693685 90 3.010532e+15 4108) popularity< 0.886855 40 4.025034e+14
                                                                                   3196752.0
                                                                                    1971924.0
                                  8216) popularity< 0.565074 9 3.732993e+11
                                                                                       254432.2
                                  8217) popularity>=0.565074 31 3.678747e+14
                                                                                       2470550.0 *
                                4109) popularity>=0.886855 50 2.500013e+15
                                  8218) popularity>=1.016719 40 1.691925e+15
8219) popularity< 1.016719 10 7.127265e+14
                                                                                      3486101.0 *
                                                                                       6938669.0 *
                       2055) popularity< 0.4693685 7 9.660623e+14
257) budget>=14.54573 36 9.222880e+14 5134069
                                                                                 7861843 0 *
                                                                      5134069.0
                          514) budget>=14.95414 19 1.808518e+14
                                                                        2918740.0
                          515) budget< 14.95414 17 5.439742e+14
                     129) runtime< 46.5 9 9.968486e+15 20005440.0 *
                    65) popularity>=1.517383 489 1.173924e+17
                                                                       7901255.0
                     130) runtime< 102.5 275 2.547281e+16 5299779.0
                       260) popularity< 4.655744 202 1.162337e+16 3865
520) runtime>=71.5 195 8.658935e+15 3508301.0
                                                                            3865514.0
## and 420 more lines.
```

#### **Vorhersage Test-Sample**

```
predict(tree_last_fit, new_data = d_test)
## # A tibble: 4,398 × 1
           .pred
##
           <dh1>
##
  1
       2031852
   2 13816447.
       2447879.
   4 48403371.
   5 10710904.
       8044510.
##
   7 10296873.
##
   8 63399160
      33470076.
## 10 372118475.
## # ... with 4,388 more rows
```

#### **RF**

#### **Fitten und Tunen**

Um Rechenzeit zu sparen, kann man das Objekt, wenn einmal berechnet, abspeichern unter result\_obj\_path auf der Festplatte und beim nächsten Mal importieren, das geht schneller als neu berechnen.

In diesem Fall hat result\_obj\_path den Inhalt tmbd\_rf\_fit1.rds.

```
if (file.exists(result_obj_path)) {
   rf_fit <- read_rds(result_obj_path)
} else {
   tic()
   rf_fit <-
        wf_rf %>%
        tune_grid(
        resamples = cv_scheme)
   toc()
}
```

Achtung Ein Ergebnisobjekt von der Festplatte zu laden ist *gefährlich*. Wenn Sie Ihr Modell verändern, aber vergessen, das Objekt auf der Festplatte zu aktualisieren, werden Ihre Ergebnisse falsch sein (da auf dem veralteten Objekt beruhend), ohne dass Sie durch eine Fehlermeldung von R gewarnt würden!

So kann man das Ergebnisobjekt auf die Festplatte schreiben:

```
#write rds(rf fit, file = "objects/tmbd rf fit1.rds")
collect metrics(rf fit)
## # A tibble: 20 × 8
##
       \verb|mtry min_n| . \verb|metric .estimator|
                                               mean
                                                        n std_err .config
      <int> <int> <chr> <chr>
                                              <dbl> <int>
                                                             <dbl> <chr>
##
                                                      15 1.71e+6 Prepro...
##
               15 rmse
                          standard
                                     82814784.
               15 rsq
                                                      15 1.15e-2 Prepro...
                           standard
                                              0.643
                                                     15 1.82e+6 Prepro...
15 1.15e-2 Prepro...
               34 rmse
                           standard
                                      82884640.
               34 rsq
                           standard
                                             0.646
                                      82457030.
##
               23 rmse
                           standard
                                                       15 1.78e+6 Prepro...
                                              0.648
               23 rsq
                           standard
                                                      15 1.15e-2 Prepro...
```

```
##
              29 rmse
                         standard
                                    82726287.
                                                     15 1.78e+6 Prepro...
              29 rsq
27 rmse
                                           0.646 15 1.13e-2 Prepro...
20. 15 1.74e+6 Prepro...
##
                         standard
## 9
                         standard
                                    82386320.
                                           20. 15 1.7.6.0 Prepro... 93. 15 1.75e+6 Prepro...
## 10
              27 rsq
                         standard
## 11
              20 rmse
                        standard
                                    83010493.
                                           0.641 15 1.23e-2 Prepro...
## 12
              20 rsq
                         standard
             10 rmse
                        standard 83920729.
                                                    15 1.72e+6 Prepro...
                                           0.634 15 1.22e-2 Prepro...
## 14
              10 rsq
                         standard
             40 rmse
40 rsq
                        standard 82786794.
## 15
                                                    15 1.78e+6 Prepro...
                                           0.642 15 1.22e-2 Prepro...
## 16
                         standard
                        standard 83237809.
                                                     15 1.71e+6 Prepro...
## 17
               9 rmse
                                                  15 1.14e-2 Prepro...
                                           0.640
## 18
               9 rsa
                         standard
               3 rmse
                        standard 83861944.
## 19
                                                    15 1.64e+6 Prepro...
                                                  15 1.12e-2 Prepro...
                                          0.635
               3 rsq
select best(rf fit)
## Warning: No value of `metric` was given; metric 'rmse' will be used.
## # A tibble: 1 × 3
##
     mtry min n .config
    <int> <int> <chr>
        2 27 Preprocessor1 Model05
Finalisieren
final wf <-
  wf rf %>%
  finalize workflow(select best(rf fit))
## Warning: No value of `metric` was given; metric 'rmse' will be used.
final fit <-
  fit(final_wf, data = d_train)
  final_fit %>%
  predict(new_data = d_test) %>%
 bind cols(d test)
```

#### Abspeichern und einreichen:

select(id, revenue = .pred)

write\_csv(submission, file = "submission.csv")

# **Kaggle Score**

Diese Submission erzielte einen Score von 2.7664 (RMSLE).

```
sol <- 2.7664
```

submission < final\_preds %>%

#### 3. Aufgabe

Wir bearbeiten hier die Fallstudie TMDB Box Office Prediction - Can you predict a movie's worldwide box office revenue?, ein Kaggle-Prognosewettbewerb.

Ziel ist es, genaue Vorhersagen zu machen, in diesem Fall für Filme.

Die Daten können Sie von der Kaggle-Projektseite beziehen oder so:

# **Aufgabe**

Reichen Sie bei Kaggle eine Submission für die Fallstudie ein! Berichten Sie den Score!

#### Hinweise:

- o Sie müssen sich bei Kaggle ein Konto anlegen (kostenlos und anonym möglich); alternativ können Sie sich mit einem Google-Konto anmelden.
- · Verwenden Sie mehrere, und zwar folgende Algorithmen: Random Forest, Boosting, lineare Regression. Tipp: Ein Workflow-Set ist hilfreich.
- Logarithmieren Sie budget.
- Betreiben Sie Feature Engineering, zumindest etwas. Insbesondere sollten Sie den Monat und das Jahr aus dem Datum extrahieren und als Features (Prädiktoren) nutzen.
- Verwenden Sie tidymodels.
- Die Zielgröße ist revenue in Dollars; nicht in "Log-Dollars". Sie müssen also rücktransformieren, falls Sie revenue logarithmiert haben.

#### Lösung

# Vorbereitung

```
library(tidyverse)
library(tidymodels)
library(tictoc)  # Rechenzeit messen
#library(Metrics)
library(lubridate)  # Datumsangaben
library(VIM)  # fehlende Werte
library(visdat)  # Datensatz visualisieren
d_train_raw <- read_csv(d_train_path)
d_test <- read_csv(d_test_path)

Mal einen Blick werfen:</pre>
```

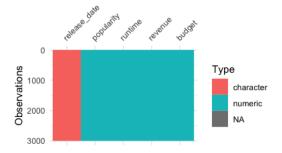
```
glimpse(d train raw)
## Rows: 3,000
## Columns: 23
## $ budget
## $ genres
## $ homepage
                       ## $ imdb_id
## $ original_language
## $ original_title
                        <chr> "When Lou, who has become the \"fathe...
## $ overview
                        <dbl> 6.575393, 8.248895, 64.299990, 3.1749...
## $ popularity
<chr> "/tQtWuwvMf0hCc2QR2tkolw17c3c.jpg", "...
## $ poster_path
                        <chr> "The Laws of Space and Time are About...
## $ tagline
                       <chr> The Laws of Space and Tame are About...
<chr> "Hot Tub Time Machine 2", "The Prince...
<chr> "[('id': 4379, 'name': 'time travel')...
<chr> "[{'cast_id': 4, 'character': 'Lou', ...
<chr> "[('credit_id': '59ac067c92514107af02...
## $ title
## $ Keywords
## $ cast
## $ crew
                        <dbl> 12314651, 95149435, 13092000, 1600000...
## $ revenue
glimpse(d test)
## Rows: 4,398
## Columns: 22
                        <dbl> 3001, 3002, 3003, 3004, 3005, 3006, 3...
## $ id
## $ belongs to collection <chr>> "[{'id': 34055, 'name': 'Pokémon Coll...
                       <dbl> 0.00e+00, 8.80e+04, 0.00e+00, 6.80e+0...
## $ budget
## $ genres
                        <chr> "[{'id': 12, 'name': 'Adventure'}, {'...
                        <chr> "http://www.pokemon.com/us/movies/mov...
## $ homepage
<chr> "ディアルガVSパルキアVSダークライ", "...
## $ original title
                        ## $ overview
## $ popularity
                        <chr> "/tnftmLMemPLduW6MRyZE0ZUD19z.jpg", '
## $ poster_path
## $ production companies <chr> NA, "[{'name': 'Woolner Brothers Pict...
<chr> "Somewhere Between Time & Space... A ...
## $ tagline
## $ title
                        <chr> "Pokémon: The Rise of Darkrai", "Atta...
## $ Keywords
                        <chr>> "[{'id': 11451, 'name': 'pokémon'}, ...
                        <chr> "[{'cast_id': 3, 'character': 'Tonio'...
<chr> "[{'credit_id': '52fe44e7c3a368484e03...
## $ cast
## S crew
```

#### Train-Set verschlanken

```
d_train <-
  d_train_raw %>%
  select(popularity, runtime, revenue, budget, release_date)
```

#### Datensatz kennenlernen

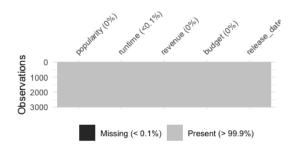
library(visdat)
vis\_dat(d\_train)



# Fehlende Werte prüfen

Welche Spalten haben viele fehlende Werte?

vis\_miss(d\_train)



Mit {VIM} kann man einen Datensatz gut auf fehlende Werte hin untersuchen:

Proportion of missing between the popularity runtime revenue budget popularity runtime revenue budget budget

# Rezept

# Rezept definieren

```
## Log transformation on budget
## Variable mutation for mdy(release_date)
## Date features from release_date
## K-nearest neighbor imputation for all_predictors()
## Dummy variables from all nominal()
tidy(rec1)
## # A tibble: 6 × 6
## number operation type
                               trained skip id
                               <lgl> <lgl> <chr>
##
     <int> <chr>
                    <chr>
## 1
         1 step
                                       FALSE mutate 6ju5z
                               FALSE
                     mutate
## 2
         2 step
                                FALSE
                                       FALSE log KAivB
                     loa
         3 step
                                FALSE
                                       FALSE mutate U01pz
                     mutate
                                FALSE
                                       FALSE date 2scL5
         4 step
## 5
         5 step
                     impute_knn FALSE
                                       FALSE impute knn 40uDg
         6 step
## 6
                     dummy
                               FALSE FALSE dummy_bQ4ok
```

### Check das Rezept

```
prep(rec1, verbose = TRUE)
## oper 1 step mutate [training]
## oper 2 step log [training]
## oper 3 step mutate [training]
## oper 4 step date [training]
## oper 5 step impute knn [training]
## oper 6 step dummy [training]
## The retained training set is \sim 0.38 Mb in memory.
## Recipe
## Inputs:
##
##
          role #variables
      outcome
\#\# Training data contained 3000 data points and 2 incomplete rows.
## Operations:
## Variable mutation for ~if else(budget < 10, 10, budget) [trained]
## Log transformation on budget [trained]
## Variable mutation for ~mdy(release_date) [trained]
## Date features from release_date [trained]
## K-nearest neighbor imputation for runtime, budget, release_date_year,... [trained]
## Dummy variables from release_date_month [trained]
d train baked <-
prep(rec1) %>%
  bake(new data = NULL)
d train baked
## # A tibble: 3,000 \times 16
      popularity runtime budget revenue release_date_year
            <dbl>
                    <dbl> <dbl>
                                        <dbl>
                      93 16.5 12314651
                                                              2015
            8.25
                        113 17.5 95149435
                                                              2004
                      105 15.0 13092000
122 14.0 16000000
   3
          64.3
                                                              2014
           3.17
##
                                                              2012
                              2.30 3923970
15.9 3261638
   5
                      118
                                                              2009
            1.15
                      83 15.9 3261638
92 16.5 85446075
84 2.30 2586511
100 2.30 34327391
           0.743
                                                              1987
                                                              2012
   8
            1.95
                                                              2004
##
   9
            6.90
                                                              1996
                        91 15.6 18750246
## 10
            4.67
                                                              2003
\#\# \# ... with 2,990 more rows, and 11 more variables:
## # release_date_month_Feb <dbl>, release_date_month_Mar <dbl>,
release_date_month_May <dbl>, release_date_month_May <dbl>,
       release_date_month_Jun <dbl>, release_date_month_Jul <dbl>,
       release_date_month_Aug <dbl>, release_date_month_Sep <dbl>,
       release_date_month_Oct <dbl>, release_date_month_Nov <dbl>,
## #
## # release_date_month_Dec <dbl>
d_train_baked %>%
  map_df(~ sum(is.na(.)))
## # A tibble: 1 × 16
## popularity runtime budget revenue release_date_ye... release_date_mo...
##
          <int> <int> <int> <int> <int> <int>
## 1
               0
                        0
                                0
                                         0
## # ... with 10 more variables: release date month Mar <int>,
## # release_date_month_Apr <int>, release_date_month_May <int>,
## # release_date_month_Jun <int>, release_date_month_Jul <int>,
## # release_date_month_Aug <int>, release_date_month_Sep <int>,
       release_date month_Oct <int>, release_date_month_Nov <int>,
release_date_month_Dec <int>
## #
```

Keine fehlenden Werte mehr in den Prädiktoren.

Nach fehlenden Werten könnte man z.B. auch so suchen:

datawizard::describe\_distribution(d\_train\_baked)

	Variable	Mean	1	SD	I	IQR	l	Range	9	Skewness	l	Kurtosis		n		n_Missing
	popularity	8.46	1	12.10	1	6.88	 I	[1.00e-06, 294.34	 	14.38	 I	280.10	 I	3000	 I	0
##	runtime	107.84	Ĺ	22.09	İ	24.00	Ĺ	[0.00, 338.00	i	1.02	ĺ	8.19	ĺ	3000	İ	0
##	budget	12.51	İ	6.44	İ	14.88	ĺ	[2.30, 19.76]	ĺ	-0.87	ĺ	-1.09		3000	ĺ	0
##	revenue	6.67e+07	1	1.38e+08	1	6.66e+07	1	[1.00, 1.52e+09]		4.54	1	27.78		3000		0
##	release_date_year	2004.58		15.48	1	17.00		[1969.00, 2068.00]		1.22	1	3.94		3000		0
##	release_date_month_Feb	0.08		0.26		0.00		[0.00, 1.00]		3.22	1	8.37		3000		0
##	release_date_month_Mar	0.08		0.27		0.00		[0.00, 1.00]		3.11	1	7.71		3000		0
##	release_date_month_Apr	0.08	1	0.27		0.00		[0.00, 1.00]		3.06		7.35		3000		0
##	release_date_month_May	0.07	1	0.26		0.00		[0.00, 1.00]		3.24		8.49		3000		0
##	release_date_month_Jun	0.08		0.27		0.00		[0.00, 1.00]		3.12	1	7.76		3000		0
##	release_date_month_Jul	0.07		0.25		0.00	1	[0.00, 1.00]		3.38		9.45		3000		0
	release_date_month_Aug	0.09		0.28		0.00		[0.00, 1.00]		2.97		6.83		3000		0
	release_date_month_Sep	0.12	1	0.33		0.00		[0.00, 1.00]		2.33		3.43		3000		0
	release_date_month_Oct	0.10	1	0.30		0.00	1	[0.00, 1.00]		2.63	1	4.90		3000		0
	release_date_month_Nov	0.07	1	0.26		0.00		[0.00, 1.00]		3.27		8.67		3000		0
##	release_date_month_Dec	0.09		0.28		0.00		[0.00, 1.00]		2.92		6.52		3000		0

So bekommt man gleich noch ein paar Infos über die Verteilung der Variablen. Praktische Sache.

### **Check Test-Sample**

Das Test-Sample backen wir auch mal. Das hat *nur* den Zwecke, zu prüfen, ob unser Rezept auch richtig funktioniert. Das Preppen und Backen des Test-Samples wir *automatisch* von predict() bzw. last\_fit() erledigt.

Wichtig: Wir preppen den Datensatz mit dem Train-Sample, auch wenn wir das Test-Sample backen wollen.

```
d_test_baked <-
    bake(rec1_prepped, new_data = d_test)
## Error in bake(rec1_prepped, new_data = d_test): object 'rec1_prepped' not found
d_test_baked %>%
    head()
## Error in head(.): object 'd_test_baked' not found
```

# Kreuzvalidierung

### Modelle

### **Baum**

#### **Random Forest**

#### **XGBoost**

#### LM

```
mod_lm <-
  linear_reg()</pre>
```

# Workflow-Set

```
preproc <- list(rec1 = rec1)
models <- list(tree1 = mod_tree, rf1 = mod_rf, boost1 = mod_boost, lm1 = mod_lm)</pre>
```

### Fitten und tunen

Wenn man das Ergebnis-Objekt abgespeichert hat, dann kann man es einfach laden, spart Rechenzeit (der Tag ist kurz):

```
result obj file <- "tmdb model set.rds"
```

(Davon ausgehend, dass die Datei im Arbeitsverzeichnis liegt.)

```
if (file.exists(result_obj_file)) {
  tmdb_model_set <- read_rds(result_obj_file)
} else {
  tic()
  tmdb_model_set <-
    all_workflows %>%
  workflow_map(
    resamples = cv_scheme,
    grid = 10,
    # metrics = metric_set(rmse),
    seed = 42, # reproducibility
    verbose = TRUE)
  toc()
}
```

Um Rechenzeit zu sparen, kann man das Ergebnisobjekt abspeichern, dann muss man beim nächsten Mal nicht wieder von Neuem berechnen:

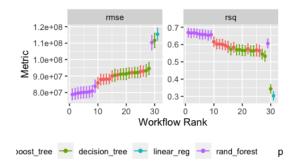
```
#write rds(tmdb model set, "objects/tmdb model set.rds")
```

### **Finalisieren**

### Welcher Algorithmus schneidet am besten ab?

Genauer geagt, welches Modell, denn es ist ja nicht nur ein Algorithmus, sondern ein Algorithmus plus ein Rezept plus die Parameterinstatiierung plus ein spezifischer Datensatz.

```
tune::autoplot(tmdb_model_set) +
  theme(legend.position = "bottom")
```



R-Quadrat ist nicht entscheidend; rmse ist wichtiger.

tmdb model set %>%

Die Ergebnislage ist nicht ganz klar, aber einiges spricht für das Boosting-Modell, rec1 boost1.

```
collect_metrics() %>%
arrange(-mean) %>%
  head(10)
## # A tibble: 10 × 9
                     .config preproc model .metric .estimator
      <chr>
                     <chr>
                               <chr>
                                         <chr> <chr>
                                                         <chr>
                                                                       <dbl> <int>
    1 rec1 lm1
                     Preproc... recipe
                                        line… rmse
                                                         standard
                                                                      1.15e8
    2 recl_tree1
3 recl_rf1
                    Preproc... recipe
                                        deci... rmse
                                                         standard
                                                                      1.12e8
                                                                                  15
                                                                      1.10e8
                    Preproc... recipe rand... rmse
                                                         standard
                                                                                  15
##
    4 recl_treel Preproc... recipe
5 recl_treel Preproc... recipe
                                                                      9.46e7
                                                         standard
                                        deci... rmse
                                        deci... rmse
                                                         standard
                                                                      9.33e7
    6 recl_boost1 Preproc... recipe
                                                         standard
                                                                      9.30e7
                                         boos... rmse
    7 recl boost1 Preproc... recipe
                                        boos... rmse
                                                         standard
                                                                      9.27e7
    8 recl_tree1 Preproc... recipe
                                        deci... rmse
                                                         standard
                                                                      9 21 67
                                                                                  15
## 9 rec1_tree1 Preproc... recipe
## 10 rec1 boost1 Preproc... recipe
                                                                      9.21e7
                                        deci... rmse
                                                         standard
                                                                                  15
                                                                      9.21e7
                                        boos... rmse
                                                         standard
## # ... with 1 more variable: std err <dbl>
best model params <-
extract workflow set result(tmdb model set, "rec1 boost1") %>%
## Warning: No value of `metric` was given; metric 'rmse' will be used.
best_model_params
```

```
## # A tibble: 1 × 4
## mtry trees min_n .config
## <int> <int> <int> <chr>
## 1 6 100 4 Preprocessor1_Model04
```

#### **Finalisieren**

best\_wf <all workflows %>%

```
extract_workflow("rec1_boost1")
best wf
## == Workflow =
## Preprocessor: Recipe
## Model: boost_tree()
## -- Preprocessor
## 6 Recipe Steps
## • step_mutate()
## • step_log()
## • step_log()
## • step_mutate()
## • step_date()
## • step_impute_knn()
## • step_dummy()
## -- Model -
## Boosted Tree Model Specification (regression)
## Main Arguments:
    mtry = tune()
     trees = tune()
##
     min_n = tune()
##
## Engine-Specific Arguments:
     nthreads = parallel::detectCores()
##
## Computational engine: xgboost
best wf finalized <-
  best wf %>%
  finalize_workflow(best_model_params)
best_wf_finalized
## == Workflow =
## Preprocessor: Recipe
## Model: boost_tree()
## -- Preprocessor
## 6 Recipe Steps
## • step_mutate()
## • step_log()
## • step_mutate()
## • step_date()
## • step_impute_knn()
## • step_dummy()
## -- Model -
## Boosted Tree Model Specification (regression)
##
## Main Arguments:
    mtry = 6
     trees = 100
     min_n = 4
##
## Engine-Specific Arguments:
## nthreads = parallel::detectCores()
## Computational engine: xgboost
Final Fit
fit final <-
  best_wf_finalized \$ \! > \! \$
  fit(d train)
## [00:20:51] WARNING: amalgamation/../src/learner.cc:576:
## Parameters: { "nthreads" } might not be used.
##
      This could be a false alarm, with some parameters getting used by language bindings but then being mistakenly passed down to XGBoost core, or some parameter actually being used
##
##
      but getting flagged wrongly here. Please open an issue if you find any such cases.
##
fit final
## == Workflow [trained] =
## Preprocessor: Recipe
## Model: boost tree()
## -- Preprocessor
## 6 Recipe Steps
##
```

```
## • step_mutate()
## • step_log()
## • step_mutate()
## • step_date()
## • step_impute_knn()
## • step dummy()
## -- Model
## #### xgb.Booster
## raw: 340.4 Kb
## call:
    xgboost::xgb.train(params = list(eta = 0.3, max_depth = 6, gamma = 0,
##
       colsample_bytree = 1, colsample_bynode = 0.4, min_child_weight = 4L, subsample = 1, objective = "reg:squarederror"), data = x$data,
##
       nrounds = 100L, watchlist = x$watchlist, verbose = 0, nthreads = 8L,
       nthread = 1)
## params (as set within xgb.train):
    eta = "0.3", max_depth = "6", gamma = "0", colsample_bytree = "1", colsample_bynode = "0.4", min_child_weight = "4", subsample = "1"
## xgb.attributes:
     niter
## callbacks:
##
    cb.evaluation.log()
## # of features: 15
## niter: 100
## nfeatures : 15
## evaluation log:
       iter training_rmse
             122301056
##
##
          2
                103897424
## ---
        99
                28913574
##
        100
                 28644486
d test$revenue <- NA
final_preds <-
  fit final %>%
  predict(new_data = d_test) %>%
  bind_cols(d_test)
```

#### **Submission**

```
submission_df <-
  final_preds %>%
  select(id, revenue = .pred)
```

#### Abspeichern und einreichen:

```
write_csv(submission_df, file = "submission.csv")
```

# Kaggle Score

Diese Submission erzielte einen Score von 4.79227 (RMSLE).

```
sol <- 4.79227
```

#### 4. Aufgabe

Wir bearbeiten hier die Fallstudie TMDB Box Office Prediction - Can you predict a movie's worldwide box office revenue?, ein Kaggle-Prognosewettbewerb.

Ziel ist es, genaue Vorhersagen zu machen, in diesem Fall für Filme.

Die Daten können Sie von der Kaggle-Projektseite beziehen oder so:

# **Aufgabe**

Reichen Sie bei Kaggle eine Submission für die Fallstudie ein! Berichten Sie den Score!

#### Hinweise:

- o Sie müssen sich bei Kaggle ein Konto anlegen (kostenlos und anonym möglich); alternativ können Sie sich mit einem Google-Konto anmelden.
- o Halten Sie das Modell so einfach wie möglich. Verwenden Sie als Algorithmus die lineare Regression ohne weitere Schnörkel.
- Logarithmieren Sie budget und revenue.
- Minimieren Sie die Vorverarbeitung (steps) so weit als möglich.
- $\circ$  Verwenden Sie tidymodels.
- Die Zielgröße ist revenue in Dollars; nicht in "Log-Dollars". Sie müssen also rücktransformieren, wenn Sie revenue logarithmiert haben, bevor Sie Ihre Prognose einreichen.

# Vorbereitung

library(tidyverse)

```
library(tidymodels)
d train raw <- read csv(d train path)
d test raw <- read csv(d test path)
 # d test$revenue <- NA
d train backup <- d train raw
Mal einen Blick werfen:
glimpse(d train raw)
## Rows: 3,000
 ## Columns: 23
```

#### Train-Set verschlanken

```
d_train_raw_reduced <-
  d train raw %>%
  select(id, popularity, runtime, revenue, budget)
```

#### Test-Set verschlanken

```
d_test_raw %>%
select(id, popularity, runtime, budget)
```

#### Outcome logarithmieren

Der Outcome sollte nicht im Rezept transformiert werden (vgl. Part 3, S. 30, in dieser Unterlage).

```
d train <-
 d train raw reduced %>%
 mutate(revenue = if_else(revenue < 10, 10, revenue)) %>%
 mutate(revenue = log(revenue))
```

Prüfen, ob das funktioniert hat:

```
d_train$revenue %>% is.infinite() %>% any()
## [1] FALSE
```

Keine unendlichen Werte mehr

# Fehlende Werte prüfen

Welche Spalten haben viele fehlende Werte?

```
sum isna <- function(x) {sum(is.na(x))}</pre>
d train %>%
 summarise(across(everything(), sum isna))
## # A tibble: 1 × 5
       id popularity runtime revenue budget
                      <int> <int> <int>
                   Ο
```

# Rezept

### Rezept definieren

```
recipe(revenue ~ ., data = d_train) %>%
  step\_mutate(budget = ifelse(\overleftarrow{budget} == 0, NA, budget)) %>%  # log mag keine 0
  step_log(budget) %>%
 step_impute_knn(all_predictors()) %>%
step_dummy(all_nominal_predictors()) %>%
 update role(id, new role = "id")
rec2
## Recipe
## Inputs:
##
         role #variables
##
           id
     outcome
   predictor
## Operations:
##
## Variable mutation for ifelse(budget == 0, NA, budget)
## Log transformation on budget
## K-nearest neighbor imputation for all_predictors()
## Dummy variables from all_nominal_predictors()
Schauen Sie mal, der Log mag keine Nullen:
x < -c(1,2, NA, 0)
log(x)
## [1] 0.0000000 0.6931472
                                    NA
                                             -Inf
Da log\left(0\right)=-\infty . Aus dem Grund wandeln wir 0 lieber in NA um.
tidy(rec2)
## # A tibble: 4 × 6
   number operation type
                                   trained skip id
##
      <int> <chr>
                       <chr>
                                   <lgl> <lgl> <chr>
## 1
        1 step
                                   FALSE
                                           FALSE mutate_Uh6zl
```

FALSE FALSE log\_3cxNv

FALSE impute knn bozlh

FALSE dummy\_PsEBM

### **Check das Rezept**

2 step

3 step

4 step

## 2

## 3

mutate

impute\_knn FALSE

FALSE

log

dummy

Wir berechnen das Rezept:

```
rec2 prepped <-
 prep(rec2, verbose = TRUE)
## oper 1 step mutate [training]
## oper 2 step log [training]
## oper 3 step impute knn [training]
## oper 4 step dummy [training]
## The retained training set is \sim 0.12 Mb in memory.
rec2 prepped
## Recipe
## Inputs:
         role #variables
##
          id
     out.come
  predictor
## Training data contained 3000 data points and 2 incomplete rows.
## Operations:
##
## Variable mutation for ~ifelse(budget == 0, NA, budget) [trained]
## Log transformation on budget [trained]
## K-nearest neighbor imputation for runtime, budget, popularity [trained]
## Dummy variables from <none> [trained]
```

Das ist noch nicht auf einen Datensatz angewendet! Lediglich die steps wurden vorbereitet, "präpariert": z.B. "Diese Dummy-Variablen impliziert das

So sieht das dann aus, wenn man das präparierte Rezept auf das Train-Sample anwendet:

```
d train baked2 <-
  rec2 prepped %>%
 bake(new_data = NULL)
head(d train baked2)
## # A tibble: 6 × 5
       id popularity runtime budget revenue
```

```
<dbl>
              <dbl> <dbl> <dbl>
           6.58
## 1 1
                     93 16.5
113 17.5
                                      16.3
## 2
              8.25
                                      18.4
                     105 15.0
122 14.0
118 15.8
83 15.9
## 3
            64.3
                                      16.4
            3.17
## 4
                                      16.6
               1.15
d train baked2 %>%
 map_df(sum_isna)
## # A tibble: 1 × 5
      id popularity runtime budget revenue
    <int>
              <int>
                       <int> <int>
```

Keine fehlenden Werte mehr in den Prädiktoren.

Nach fehlenden Werten könnte man z.B. auch so suchen:

datawizard::describe\_distribution(d\_train\_baked2)

	Variable		Mean		SD	1	IQR			Range	-	Skewness		Kurtosis		n		n_Missing
	id		1500.50		866.17	1	1500.50	1	[1.00,	3000.00]	1	0.00	1	-1.20	1	3000		0
##	popularity		8.46		12.10		6.88		[1.00e-06,	294.34]		14.38		280.10		3000		0
##	runtime		107.85		22.08		24.00		[0.00,	338.00]		1.02		8.20		3000		0
##	budget		16.09		1.89		1.90		[0.0]	), 19.76]		-2.93		18.71		3000		0
##	revenue		15.97		3.04	-	3.37		[2.30	), 21.14]	-	-1.60		3.82		3000		0

So bekommt man gleich noch ein paar Infos über die Verteilung der Variablen. Praktische Sache.

### **Check Test-Sample**

Das Test-Sample backen wir auch mal, um zu prüfen, das alles läuft:

Sieht soweit gut aus.

# Kreuzvalidierung

# Modelle

### LM

```
mod_lm <-
  linear reg()</pre>
```

### Workflow-Set

Hier nur ein sehr kleiner Workflow-Set.

Das ist übrigens eine gute Strategie: Erstmal mit einem kleinen Prozess anfangen, und dann sukzessive erweitern.

```
preproc2 <- list(rec1 = rec2)
models2 <- list(lm1 = mod_lm)

all workflows2 <- workflow set(preproc2, models2)</pre>
```

# Fitten und tunen

```
tmdb_model_set2 <-
   all_workflows2 %>%
   workflow_map(resamples = cv_scheme)
```

### **Finalisieren**

```
tmdb_model_set2 %>%
        collect_metrics() %>%
        arrange(-mean) %>%
       head(10)
 ## # A tibble: 2 × 9
 ## wflow_id .config
                                                                                                   preproc model .metric .estimator mean
                                                                                                                                                                                                                      <dbl> <int>
## <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr> <chr
 ## 2 rec1 lm1 Preprocessor... recipe line... rsq
                                                                                                                                                                               standard 0.338
 ## # ... with 1 more variable: std err <dbl>
best_model_params2 <-
extract_workflow_set_result(tmdb_model_set2, "rec1_lm1") %>%
       select best()
## Warning: No value of `metric` was given; metric 'rmse' will be used.
best_model_params2
 ## # A tibble: 1 × 1
            .config
 ##
                  <chr>
## 1 Preprocessor1 Model1
```

#### **Finalisieren**

Finalisieren bedeutet:

- Besten Workflow identifizieren (zur Erinnerung: Workflow = Rezept + Modell)
- o Den besten Workflow mit den optimalen Modell-Parametern ausstatten
- o Damit dann den ganzen Train-Datensatz fitten
- o Auf dieser Basis das Test-Sample vorhersagen

```
best_wf2 <-
all_workflows2 \$>\$
  extract_workflow("rec1_lm1")
best wf2
## == Workflow =
## Preprocessor: Recipe
## Model: linear reg()
## -- Preprocessor
## 4 Recipe Steps
## • step_mutate()
## • step_log()
## • step_impute_knn()
## • step_dummy()
## -- Model -
## Linear Regression Model Specification (regression)
## Computational engine: lm
best wf finalized2 <-
  best wf2 %>%
  finalize workflow(best model params2)
best_wf_finalized2
## == Workflow :
## Preprocessor: Recipe
## Model: linear reg()
## -- Preprocessor
## 4 Recipe Steps
## • step_mutate()
## • step_log()
## • step_impute_knn()
## • step_dummy()
##
## Linear Regression Model Specification (regression)
## Computational engine: lm
```

#### **Final Fit**

```
## -- Preprocessor
## 4 Recipe Steps
##
## • step_mutate()
## • step_log()
## • step_impute_knn()
## • step_dummy()
##
## -- Model -
##
## Call:
## stats::lm(formula = ..y ~ ., data = data)
## Coefficients:
## (Intercept) popularity
                                 runtime
                                                budget
                               0.01289
##
      1.26186
                   0.03755
                                               0.80752
preds <-
fit_final2 %>%
 predict(new_data = d_test)
head (preds)
## # A tibble: 6 × 1
    .pred
    <db1>
## 1 15.3
## 2 11.4
## 3 16.1
## 4 16.0
## 5 14.3
## 6 16.1
```

Achtung, wenn die Outcome-Variable im Rezept verändert wurde, dann würde obiger Code nicht durchlaufen.

Grund ist hier beschrieben:

When predict() is used, it only has access to the predictors (mirroring how this would work with new samples). Even if the outcome column is present, it is not exposed to the recipe. This is generally a good idea so that we can avoid information leakage.

One approach is the use the skip = TRUE option in step\_log() so that it will avoid that step during predict() and/or bake(). However, if you are using this recipe with the tune package, there will still be an issue because the metric function(s) would get the predictions in log units and the observed outcome in the original units.

The better approach is, for simple transformations like yours, to log the outcome outside of the recipe (before data analysis and the initial split).

#### Submission df

```
submission df <-
 d_test %>%
  select(id) %>%
  bind cols(preds) %>%
 rename (revenue = .pred)
head(submission df)
## # A tibble: 6 × 2
       id revenue
##
    <dbl>
            <dbl>
## 1 3001
             15.3
## 2 3002
             11 4
## 3 3003
             16.1
## 4 3004
             16.0
      3005
              14.3
      3006
```

### Zurücktransformieren

<u>Hier</u> ein Beispiel, warum  $e^x - 1$  genauer ist für kleine Zahlen als  $e^x$ .

#### Abspeichern und einreichen:

```
write_csv(submission_df, file = "submission.csv")
```

# **Kaggle Score**

Diese Submission erzielte einen Score von Score: 2.46249 (RMSLE).

```
sol <- 2.5
```

#### 5. Aufgabe

Melden Sie sich an für die Kaggle Competition TMDB Box Office Prediction - Can you predict a movie's worldwide box office revenue?

Sie benötigen dazu ein Konto; es ist auch möglich, sich mit seinem Google-Konto anzumelden.

Bei diesem Prognosewettbewerb geht es darum, vorherzusagen, wieviel Umsatz wohl einige Filme machen werden. Als Prädiktoren stehen einige Infos wie Budget, Genre, Titel etc. zur Verfügung. Eine klassische "predictive Competition" also :-) Allerdings können immer ein paar Schwierigkeiten auftreten ;-)

#### Aufgabe

Erstellen Sie ein Random-Forest-Modell mit Tidymodels!

#### Hinweise

- · Verzichten Sie auf Vorverarbeitung.
- Tunen Sie die typischen Parameter.
- Reichen Sie das Modell ein und berichten Sie Ihren Score.
- Begrenzen Sie sich auf folgende Prädiktoren.
- o Verwenden Sie (langweiligerweise) nur ein lineares Modell.

```
preds_chosen <-
  c("id", "budget", "popularity", "runtime")</pre>
```

#### Lösung

### Pakete starten

```
library(tidyverse)
library(tidymodels)
library(tictoc)
```

# **Daten importieren**

```
d_train_path <- "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/tmdb-box-office-prediction/train.csv"
d_test_path <- "https://raw.githubusercontent.com/sebastiansauer/Lehre/main/data/tmdb-box-office-prediction/test.csv"

d_train <- read_csv(d_train_path)
d_test <- read_csv(d_test_path)</pre>
```

#### Werfen wir einen Blick in die Daten:

```
glimpse(d train)
## Rows: 3,000
## Columns: 23
## $ budget
                  <dbl> 1.40e+07, 4.00e+07, 3.30e+06, 1.20e+0...
<chr> "When Lou, who has become the \"fathe...
## $ overview
<dbl> 2/20/13, 6/6/04, 10/10/14, 5/9...
<dbl> 93, 113, 105, 122, 118, 83, 92, 84, 1...
<chr> "[{'iso_639_1': 'en', 'name': 'Englis...
<chr> "Released", "Released", "Released", "...
<chr> "The Laws of Space and Time are About...
## $ runtime
## $ spoken_languages
## $ status
## $ tagline
                           <chr> "Hot Tub Time Machine 2", "The Prince...
## $ title
## $ Keywords
                          <chr> "[{'id': 4379, 'name': 'time travel'}...
                           <chr> "[('cast_id': 4, 'character': 'Lou', ...
<chr> "[{'credit_id': '59ac067c92514107af02...
## $ cast
## $ revenue
                           <dbl> 12314651, 95149435, 13092000, 1600000...
glimpse(d test)
## Rows: 4.398
## Columns: 22
## $ id
                            <dbl> 3001, 3002, 3003, 3004, 3005, 3006, 3...
```

```
## $ belongs_to_collection <chr>> "[{'id': 34055, 'name': 'Pokémon Coll...
                      ## $ budget
## $ genres
                       <chr> "http://www.pokemon.com/us/movies/mov...
## $ homepage
<chr> "Ash and friends (this time accompani...
## $ overview
## $ popularity
                      <dbl> 3.851534, 3.559789, 8.085194, 8.59601...
## $ poster path
                       <chr> "/tnftmLMemPLduW6MRyZE0ZUD19z.jpg",
## $ tagline
                       <chr> "Somewhere Between Time & Space... A ...
## $ title
                       <chr> "Pokémon: The Rise of Darkrai", "Atta...
                       <chr> "[{'id': 11451, 'name': 'pok√@mon'}, ... <chr> "[{'cast_id': 3, 'character': 'Tonio'...
## $ Keywords
## $ cast
                       <chr> "[{'credit_id': '52fe44e7c3a368484e03...
## $ crew
preds chosen sind alle Prädiktoren im Datensatz, oder nicht? Das prüfen wir mal kurz:
preds_chosen %in% names(d_train) %>%
 all()
## [1] TRUE
```

Ja, alle Elemente von preds chosen sind Prädiktoren im (Train-)Datensatz.

### CV

cv scheme <- vfold cv(d train)

# Rezept 1

Man beachte, dass noch 21 Prädiktoren angezeigt werden, da das Rezept noch nicht auf den Datensatz angewandt ("gebacken") wurde.

#### Rezept checken:

tidy(rec1)

```
prep (rec1)
## Recipe
## Inputs:
##
        role #variables
     outcome
   predictor
\#\# Training data contained 3000 data points and 2 incomplete rows.
## Operations:
## Bagged tree imputation for budget, popularity, runtime [trained]
## Removing rows with NA values in budget, popularity, runtime [trained]
d train baked <-
  rec1 %>%
  prep() %>%
  bake(new data = NULL)
glimpse(d train baked)
```

### Modell 1

model\_lm <- linear\_reg()</pre>

### **Workflow 1**

```
wf1 <-
  workflow() %>%
  add_model(model_lm) %>%
  add recipe(rec1)
```

# Modell fitten (und tunen)

```
doParallel::registerDoParallel(4)
tic()
lm_fit1 <-
    wf1 %>%
    tune_grid(resamples = cv_scheme)

## Warning: No tuning parameters have been detected, performance will
## be evaluated using the resamples with no tuning. Did you want to
## [tune()] parameters?

toc()

## 2.734 sec elapsed

lm_fit1[[".notes"]][1]

## [[1]]
## [[1]]
## # A tibble: 0 × 3
## # ... with 3 variables: location <chr>, type <chr>, note <chr>
```

# **Final Fit**

```
fit1_final <-
  wf1 %>%
  fit(d_train)
fit1 final
## == Workflow [trained]
## Preprocessor: Recipe
## Model: linear_reg()
## -- Preprocessor -
## 2 Recipe Steps
## • step_impute_bag()
## • step_naomit()
##
## -- Model -
##
## Call:
## stats::lm(formula = ..y ~ ., data = data)
## Coefficients:
## (Intercept) budget popularity
## -2.901e+07 2.482e+00 2.604e+06
                                                 runtime
                                              1.648e+05
  fit1_final %>%
  predict(d_test)
```

# Submission df

```
submission_df <-
  d_test %>%
  select(id) %>%
  \verb|bind_cols(preds)| \%>\%
  rename (revenue = .pred)
head(submission_df)
## # A tibble: 6 × 2
    id revenue <dbl> <dbl>
## 1 3001 -4147868.
## 2 3002 -8809025.
## 3 3003 8523824.
## 4 3004 31675556.
## 5 3005 -504679.
## 6 3006 13531638.
Abspeichern und einreichen:
#write_csv(submission_df, file = "submission.csv")
```

# Kaggle Score

Diese Submission erzielte einen Score von Score: 6.14787 (RMSLE).

```
sol <- 6.14787
```

#### 6. Aufgabe

Ein merkwürdiger Fehler bzw. eine merkwürdige Fehlermeldung in Tidymodels - das untersuchen wir hier genauer und versuchen das Phänomen zu erklären.

#### Aufgabe

Erläutern Sie die Ursachen des Fehlers! Schalten Sie den Fehler an und ab, um zu zeigen, dass Sie Ihn verstehen.

# **Startup**

```
library(tidyverse)
library(tidymodels)
```

# **Data import**

```
data("mtcars")
d_train <- mtcars %>% slice(1:20)
d test <- mtcars %>% slice(21:nrow(mtcars))
```

# Recipe

```
preds_chosen <- c("hp", "disp", "am")</pre>
rec1 <-
  recipe( ~ ., data = d train) %>%
  update_role(all_predictors(), new_role = "id") %>%
update_role(all_of(preds_chosen), new_role = "predictor") %>%
  update_role(mpg, new_role = "outcome")
rec1
## Recipe
## Inputs:
##
           role #variables
             id
## predictor
d_train_baked <-
  rec1 %>%
  prep() %>%
  bake(new_data = NULL)
glimpse(d_train_baked)
## Rows: 20
## Columns: 11
## $ cyl <dbl> 21.0, 21.0, 22.8, 21.4, 18.7, 18.1, 14.3, 24.4, 22.8, ...
## $ cyl <dbl> 6, 6, 4, 6, 8, 6, 8, 4, 4, 6, 6, 8, 8, 8, 8, 8, 8, 8, 4, ...
## $ disp <dbl> 160.0, 160.0, 108.0, 258.0, 360.0, 225.0, 360.0, 146.7...
            <dbl> 110, 110, 93, 110, 175, 105, 245, 62, 95, 123, 123, 18...
## $ hp
## $ drat <dbl> 3.90, 3.90, 3.85, 3.08, 3.15, 2.76, 3.21, 3.69, 3.92,
           <dbl> 2.620, 2.875, 2.320, 3.215, 3.440, 3.460, 3.570, 3.190...
## $ wt
```

### Model 1

```
model_lm <- linear_reg()</pre>
```

### Workflow 1

```
wf1 <-
  workflow() %>%
  add_model(model_lm) %>%
  add_recipe(rec1)
```

### Fit

```
lm fit1 <-
  wf1 %>%
  fit(d_train)
  lm_fit1 %>%
  predict(d_test)
head (preds)
## # A tibble: 6 × 1
     .pred
   <db1>
## 1 22.6
## 2 17.2
## 3 17.4
## 4 12.1
## 5
     14.9
## 6 28.2
```

Aus Gründen der Reproduzierbarkeit bietet es sich an, eine SessionInfo anzugeben:

```
sessionInfo()
## R version 4.1.3 (2022-03-10)
## Platform: x86_64-apple-darwin17.0 (64-bit)
## Running under: macOS Monterey 12.3.1
## Matrix products: default
## LAPACK: Library/Frameworks/R.framework/Versions/4.1/Resources/lib/libRlapack.dylib
## locale:
## [1] en_US.UTF-8/en_US.UTF-8/en_US.UTF-8/C/en_US.UTF-8/en_US.UTF-8
##
## attached base packages:
                            graphics grDevices utils datasets
## [1] grid
                 stats
## [7] methods
                 base
## other attached packages:
                             VIM_6.1.1
    [1] visdat_0.5.3
                                                   colorspace_2.0-3
    [4] lubridate_1.8.0
                             rpart_4.1.16
see_0.7.0.1
                                                   ranger_0.13.1 correlation 0.8.0.1
    [7] report 0.5.1.1
                              effectsize_0.6.0.1 parameters_0.17.0.9
## [10] modelbased 0.8.0
   [13] performance_0.9.0.2 bayestestR_0.12.1
                                                   datawizard_0.4.0.17
## [16] insight_0.17.0.6 easystats_0.4.3
                                                   tictoc_1.0.1
## [19] yardstick_0.0.9
                              workflowsets_0.1.0 workflows_0.2.6
## [22] tune_0.2.0.9000
                              rsample_0.1.1
                                                   recipes_0.2.0
                                                  infer_1.0.0
broom_0.8.0
stringr_1.4.0
                             modeldata 0.1.1
## [25] parsnip 0.2.1
## [28] dials 0.1.1
                              scales 1.\overline{2.0}
## [31] tidymodels_0.1.4 forcats_0.5.1
## [34] purrr_0.3.4
## [37] tibble_3.1.7
## [40] exams_2.3-6
                              readr_2.1.2
                              ggplot2_3.3.6
                                                   tidyverse_1.3.1
                             dplyr_1.0.9
                                                   colorout_1.2-2
## loaded via a namespace (and not attached):
                          backports_1.4.1
     [1] readxl_1.3.1
                                                 primes_1.1.0
                              sp_1.4-6
     [4] plyr_1.8.7
                                                   splines_4.1.3
##
     [7] listenv_0.8.0
                              TH.data_1.1-1
                                                   digest_0.6.29
                           htmltools_0.5.2
    [10] foreach 1.5.2
                                                   fansi 1.0.3
                             doParallel 1.0.17 openxlsx 4.2.5
##
    [13] magrittr_2.0.3
                             globals_0.14.0
vroom_1.5.7
                                                  modelr_0.1.8
    [16] tzdb_0.1.2
[19] gower 1.0.0
                                                  sandwich 3.0-1
    [22] hardhat_0.2.0
                             rvest 1.0.2
                                                  haven 2.\overline{4}.3
    [25] xfun_0.30
                              crayon_1.5.1
                                                  jsonlite_1.8.0
##
    [28] survival 3.2-13
                              zoo 1.8-9
                                                  iterators 1.0.14
                              gtable_0.3.0
                                                  ipred_0.9-12
    [31] glue_1.6.2
    [34] emmeans 1.7.3
                              car 3.\overline{0}-11
                                                  future.apply 1.8.1
    [37] DEoptimR 1.0-10
                              abind 1.4-5
                                                  mvtnorm 1.1-3
    [40] DBI 1.1.2
                              Rcpp \overline{1.0.8.3}
                                                  laeken_0.5.2
    [43] xtable 1.8-4
                              foreign 0.8-82
                                                  proxy 0.4-26
    [46] GPfit \overline{1.0-8}
                              bit 4.0.4
                                                  lava_1.6.10
    [49] prodlim_2019.11.13 vcd_1.4-9
                                                  httr_1.4.3
```

```
## [52] ellipsis_0.3.2 farver_2.1.0 pkgconfig_2.0.3 utf8 [1.2.2]
## [55] nnet 7.3-17 dbplyr_2.1.1 utf8 [1.2.2]
## [58] labeling_0.4.2 tidyselect_1.1.2 rlang_1.0.2
## [61] Dicebesign_1.9 munsell_0.5.0 cellranger_1.1.0
## [64] tools_4.1.3 xgboost_1.5.2.1 cli_3.3.0
## [67] generics_0.1.2 evaluate_0.15 fastmap_1.1.0 ffs_1.5.2
## [70] knitr_1.39 bit64_4.0.5 fs_1.5.2
## [73] zip_2.2.0 robustbase_0.93-9
## [76] xml2_1.3.3 compiler_4.1.3 reprex_2.0.1
## [82] lhs_1.1.5 stringi_1.7.6 highr_0.9
## [88] pilar_1.7.0 lifecycle_1.0.1 furrr_0.2.3
## [88] pilar_1.7.0 estimability_1.3 data.table_1.14.2
## [94] R6_2.5.1 rio_0.5.29 parallelly_1.31.0
## [97] codetools_0.2-18 boot_1.3-28 mss_7.3-55
## [100] asserthat_0.2.1 withr_2.5.0 multcomp_1.4-19
## [106] coda_0.19-4 class_7.3-20 rmarkdown_2.14
## [109] carData_3.0-4 pROC_1.18.0 base64enc_0.1-3
```

#### Lösung

Definiert man das Rezept so:

```
rec2 <- recipe(mpg ~ hp + disp + am, data = d train)
```

Dann läuft predict () brav durch.

Auch dieser Code funktioniert:

```
rec3 <-
  recipe(mpg ~ ., data = d_train) %>%
  update_role(all_predictors(), new_role = "id") %>%
  update_role(all_of(preds_chosen), new_role = "predictor") %>%
  update_role(mpg, new_role = "outcome")
```

Das Problem von rec1 scheint darin zu legen, dass die Rollen der Variablen nicht richtig gelöscht werden, was predict () verwirrt:

```
rec1 <-
    recipe(mpg ~ ., data = d_train) %>%
    update_role(all_predictors(), new_role = "id") %>%
    update_role(all_of(preds_chosen), new_role = "predictor") %>%
    update_role(mpg, new_role = "outcome")
rec1

## Recipe
##
## Inputs:
##
## role #variables
## id 7
## outcome 1
## predictor 3
```

Daher läuft das Rezept rec3 durch, wenn man zunächst alle Prädiktoren in ID-Variablen umwandelt: Damit sind alle Rollen wieder sauber.